

# Éléments de compréhension des statistiques

Jeffery P.

Doctorant au Laboratoire des Sciences du Numérique de Nantes (LS2N)

2019


# Crédits

- ▶ Ce support est inspiré du cours de M. Jean-Philippe Babin, responsable pédagogique de Licence à l'Université de Nantes - Laboratoire de Psychologie des Pays de la Loire.
- ▶ Également, plusieurs formulations ont pu être améliorées grâce aux commentaires avisés de M. Paul Marti et M. Damien Schnebelen, tous deux doctorants au LS2N - pôle SIEL, team PACCE.

# La loi normale

# Introduction

S'il y a bien une loi populaire en statistique, il s'agit de la loi normale. . .la célèbre courbe en cloche !




# Caractéristiques de la loi normale

- ▶ La loi normale est une loi **symétrique, centrée autour de sa moyenne**
- ▶ La symétrie de la distribution implique que **la médiane est égale à la moyenne**
- ▶ C'est une loi unimodale, **son mode est égale à la moyenne**

# Reconnaître une loi normale

En pratique, on peut supposer une distribution normale d'après l'histogramme, ou le diagramme en barre



# Quelques mots sur la loi normale

- ▶ La loi normale est définie par deux paramètres :
- 1. Sa moyenne souvent notée  $\mu$  (où *mean*)
- 2. Son écart-type notée  $\sigma$  (où *sd* pour “Standard Deviation”)

Sa densité de probabilité est la suivante :


$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \times \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

avec une variable  $X$  qui suit une loi normale de moyenne  $\mu$  et d'écart-type  $\sigma$

On note  $X \sim N(\mu, \sigma^2)$

# Illustration de la loi normale


Changer la moyenne d'une loi normale revient à translater la distribution vers la droite ou la gauche





# Illustration de la loi normale

Changer l'écart-type d'une loi normale revient à aplatir ou resserrer sa distribution autour de sa moyenne




# Propriété intéressante

Si l'on dispose d'observations d'une distribution  $N(\mu, \sigma^2)$  alors :

- ▶ 68% des observations sont comprises dans l'intervalle  $[\mu - \sigma; \mu + \sigma]$
- ▶ 95% des observations sont comprises dans l'intervalle  $[\mu - 2\sigma; \mu + 2\sigma]$
- ▶ 99,8% des observations sont comprises dans l'intervalle  $[\mu - 3\sigma; \mu + 3\sigma]$

# Estimation graphique de $\mu$ et $\sigma$

- En pratique on estime  $\mu$  en prenant le centre de la distribution, et on déduit  $\sigma$  en estimant l'intervalle vert



# Calcul de probabilité : généralité

La probabilité pour qu'une variable aléatoire  $X$  soit inférieure à une quelconque valeur  $x$  s'écrit  $P(X \leq x)$

- **Un probabilité est toujours positive et inférieure à 1**

## Remarque

- Pour une variable aléatoire réelle on a :  
 $P(-\infty < X < +\infty) = 1$
- Pour une variable continue, on a  $P(X = x) = 0$ , d'où :


$$P(X \leq x) = P(X < x) \text{ où encore } P(X \geq x) = P(X > x)$$

Ce résultat s'explique avec un peu de théorie mathématique que l'on ne détaillera pas ici, mais il peut être utile d'avoir ces propriétés en tête pour les exercices. . .

# Calcul de probabilité : lien avec l'aire sous la courbe de densité

**Cas 0** : soit  $Z \sim N(0, 1)$ , l'aire sous la courbe est égale à 1


$$P(-\infty < Z < +\infty) = 1$$



# Calcul de probabilité : valeurs de la table

**Cas I** : soient  $Z \sim N(0, 1)$  et  $a$  un nombre réel **positif**



$P(Z \leq a) \rightarrow$  le résultat se trouve dans la table !



# Calcul de probabilité avec la loi normale

**Cas II** : soient  $Z \sim N(0, 1)$  et  $a$  un nombre réel **positif**



$P(Z \geq a) = 1 - P(Z \leq a) \rightarrow$  on se ramène au **cas I**



# Calcul de probabilité avec la loi normale

**Cas III** : soient  $Z \sim N(0, 1)$  et  $a$  un nombre réel **positif**

$P(Z \leq -a) = P(Z \geq a) \longrightarrow$  on se ramène au **cas II**







# Calcul de probabilité avec la loi normale

**Cas IV** : soient  $Z \sim N(0, 1)$  et  $a$  un nombre réel **positif**

$P(Z \geq -a) = P(Z \leq a) \rightarrow$  on se ramène au **cas I**



# Résumé

[Calcul de probabilité (*Extrait du cours de M. Gérin, Paris Ouest 2012-2013*)] [normale]

## Formule de calcul avec une intervalle quelconque


Soient  $Z \sim N(0, 1)$  et  $u, v$  deux nombres réels avec  $u \leq v$

$$P(u \leq Z \leq v) = P(Z \leq v) - P(Z \leq u)$$

# Calcul de probabilité avec la loi normale

**Cas V.1** : soient  $Z \sim N(0, 1)$  et  $0 \leq a \leq b$


$$P(a \leq Z \leq b) = P(Z \leq b) - P(Z \leq a)$$



# Calcul de probabilité avec la loi normale

**Cas V.2** : soient  $Z \sim N(0, 1)$  et  $0 \leq a \leq b$


$$P(-a \leq Z \leq b) = P(Z \leq b) - P(Z \leq -a) = P(Z \leq b) + P(Z \leq a) - 1$$



# Calcul de probabilité avec la loi normale

**Cas V.3** : soient  $Z \sim N(0, 1)$  et  $-a \leq -b \leq 0$

$$P(-a \leq Z \leq -b) = P(Z \leq -b) - P(Z \leq -a) = P(Z \leq a) - P(Z \leq b)$$



# Transformation de la loi normale

Toute transformation *affine* d'une loi normale est encore une loi normale i.e., quelque soit les nombre réels  $a$  et  $b \neq 0$  on a :

$$X \sim N(\mu, \sigma^2) \Rightarrow aX + b \sim N(\mu + b, a^2 \times \sigma^2)$$

Par conséquent :

- ▶ si  $X \sim N(\mu, \sigma^2)$  alors  $X - \mu \sim N(0, \sigma^2)$  (**centrage**)
- ▶ si  $X \sim N(\mu, \sigma^2)$  alors  $\frac{X}{\sigma} \sim N(\mu, 1)$  (**réduction**)

En pratique, on fait souvent les deux en même temps :

- ▶ si  $X \sim N(\mu, \sigma^2)$  alors  $\frac{X-\mu}{\sigma} \sim N(0, 1)$   
(**normalisation=centrage+réduction**)

# Calcul de probabilité : en pratique

Si la variable  $X$  ne suit pas une loi normale centrée réduite, on peut toujours se ramener aux cas précédents, par exemple :

$$P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{x - \mu}{\sigma}\right)$$

Où  $Z \sim N(0, 1)$

→ Rappel : il s'agit de la **normalisation**, cette petite transformation est très utile et beaucoup utilisée !



## Cas pratique : calcul de probabilité

68% des observations sont comprises dans l'intervalle  $[\bar{x} - \sigma; \bar{x} + \sigma]$ . . . Est-ce bien vrai ?

$$\begin{aligned}P(\bar{x} - \sigma \leq X \leq \bar{x} + \sigma) &= P(-\sigma \leq X - \bar{x} \leq \sigma), \quad \text{on centre} \\&= P(-1 \leq \frac{X - \bar{x}}{\sigma} \leq 1), \quad \text{on réduit} \\&= P(-1 \leq Z \leq 1)\end{aligned}$$

Où  $Z \sim N(0, 1)$

Il faut maintenant trouver la valeur de cette probabilité sur les tables. . .

## Cas pratique

$$\begin{aligned}P(\bar{x} - \sigma \leq X \leq \bar{x} + \sigma) &= P(-1 \leq Z \leq 1) \\&= P(Z \leq 1) - P(Z \leq -1) \\&= P(Z \leq 1) - (1 - P(Z \leq 1)) \\&= 2P(Z \leq 1) - 1\end{aligned}$$

Où  $Z \sim N(0, 1)$

### Remarque

Plus généralement, on a la formule suivante quelque soit  $k$  nombre entier positif :

$$P(\bar{x} - k \times \sigma \leq X \leq \bar{x} + k \times \sigma) = P(-k \leq Z \leq k)$$

# Calcul des quantiles


Dans certains cas, on ne cherche pas à calculer une probabilité pour un  $b$  donné (e.g.,  $P(Z \leq b)$ ) mais on cherche  $b$  telle que la probabilité soit égale à une certaine valeur :

On veut trouver  $b$  tel que  $P(X \geq b) = \alpha$  où  $P(|X| \geq b) = \alpha$

- ▶ Dans ce cas, on s'assure que la probabilité concerne une variable suivant une **loi normale centrée réduite**, puis on regarde dans une des tables


# Calcul des quantiles : table 1

On recherche une valeur  $z$  telle que  $P(Z > z)$  avec  $Z \sim N(0, 1)$  :



## Calcul des quantiles : table 2

On recherche une valeur  $z$  telle que  $P(|Z| > z)$  avec  $Z \sim N(0, 1)$  :



# Calcul des quantiles

Attention, cette problématique est faussement facile... dans la majorité des cas elle nécessite une bonne maîtrise du calcul des probabilités de la loi normale !

## Cas fréquents

- ▶ On ne demande pas de trouver  $z$  tel que  $P(Z \geq z) = \alpha$  mais plutôt  $P(Z \leq z) = 1 - \alpha$ .
- ▶ On ne demande pas de trouver  $z$  tel que  $P(|Z| \geq z) = \alpha$  mais plutôt  $P(|Z| \leq z) = 1 - \alpha$ .
- ▶ La probabilité porte sur une variable  $X \sim N(\mu, \sigma^2)$ . Il faut bien penser à centrer et réduire l'évènement (ce qui se trouve dans la probabilité) e.g.,  $P(X > x) = P(Z > \frac{x-\mu}{\sigma})$  où  $Z \sim N(0, 1)$

# Calcul des quantiles

## Exemple général (théorique mais utile !)

Soit  $X \sim N(\mu, \sigma)$ , on suppose  $\alpha \in ]0; 0.5[$  connu.

**On cherche  $b$  tel que  $P(X > b) = \alpha$**

Voici les étapes qui nous permettent de trouver la solution :


$$\begin{aligned} P(X > b) &= \alpha \\ \Leftrightarrow P\left(Z > \frac{b-\mu}{\sigma}\right) &= \alpha \\ \Leftrightarrow P\left(Z \leq \frac{b-\mu}{\sigma}\right) &= 1 - \alpha \\ \Rightarrow \frac{b-\mu}{\sigma} &= Z_{(1-\alpha)} \\ \text{Donc } b &= \mu + \sigma \times Z_{(1-\alpha)} \end{aligned}$$

Avec :

- ▶  $Z \sim N(0, 1)$
- ▶  $z_{(1-\alpha)}$  est le **quantile** d'ordre  $(1 - \alpha)$  de la loi normale centrée réduite

# Calcul des quantiles

## ► Rappel sur la position des déciles et quantiles extrêmes





# Calcul des quantiles

Soit  $X \sim N(\mu, \sigma)$

## Détermination des déciles et quartiles extrêmes

En utilisant la formule précédente, il vient :

$$\begin{aligned} P(X > Q_3) &= 0.25 \\ \Rightarrow Q_3 &= \mu + \sigma \times Z_{(0.75)} \end{aligned}$$

$$\begin{aligned} P(X > D_9) &= 0.1 \\ \Rightarrow D_9 &= \mu + \sigma \times Z_{(0.9)} \end{aligned}$$

Pour rappel :

- ▶  $Q_3$  : troisième quartile
- ▶  $D_9$  : neuvième décile

# Calcul des quantiles

Soit  $X \sim N(\mu, \sigma)$

## Détermination des déciles et quartiles extrêmes

Pour  $D_1$  et  $Q_1$ , le calcul est un peu **sioux**. Par exemple pour  $D_1$ , on a :

$$\begin{aligned} P(X > D_1) &= 0.9 \\ \Leftrightarrow P(Z > \frac{D_1 - \mu}{\sigma}) &= 0.9 \quad \text{or } \frac{D_1 - \mu}{\sigma} < 0 \\ \Leftrightarrow P(Z \leq -\frac{D_1 - \mu}{\sigma}) &= 0.9 \\ \Rightarrow -\frac{D_1 - \mu}{\sigma} &= Z_{(0.9)} \\ \text{Donc } D_1 &= \mu - \sigma \times Z_{(0.9)} \end{aligned}$$

# Calcul des quantiles

Soit  $X \sim N(\mu, \sigma)$

## Détermination des déciles et quartiles extrêmes

On peut utiliser les formules suivantes pour  $D_1$  et  $Q_1$  :

$$Q_1 = \mu - \sigma \times Z_{(0.75)} = 2 \times \mu - Q_3$$

$$D_1 = \mu - \sigma \times Z_{(0.9)} = 2 \times \mu - D_9$$

Avec :

- ▶  $Q_1$  : premier quartile i.e.,  $P(X \geq Q_1) = 0.75$
- ▶  $Q_3$  : troisième quartile i.e.,  $P(X \geq Q_3) = 0.25$
- ▶  $D_1$  : premier décile i.e.,  $P(X \geq D_1) = 0.9$
- ▶  $D_9$  : neuvième décile i.e.,  $P(X \geq D_9) = 0.1$